이기종 환경 멀티모달 추론최적화

LLM-Pilot 확장

- LLM-Pilot
  - 클라우드 환경에서 Offloading 전략을 통한 LLM 추론 서빙 시 인스턴스 구성 최적화 솔버
    - AWS 인스턴스 환경의 가격 비교 (1시간 단위 비용 청구)
      - 자원이 묶여있는 환경
    - KVO, AO 전략 활용
    - 비용 효율성 지표
    - SLO를 만족하며 가장 비용 효율적인 인스턴스 구성을 추천

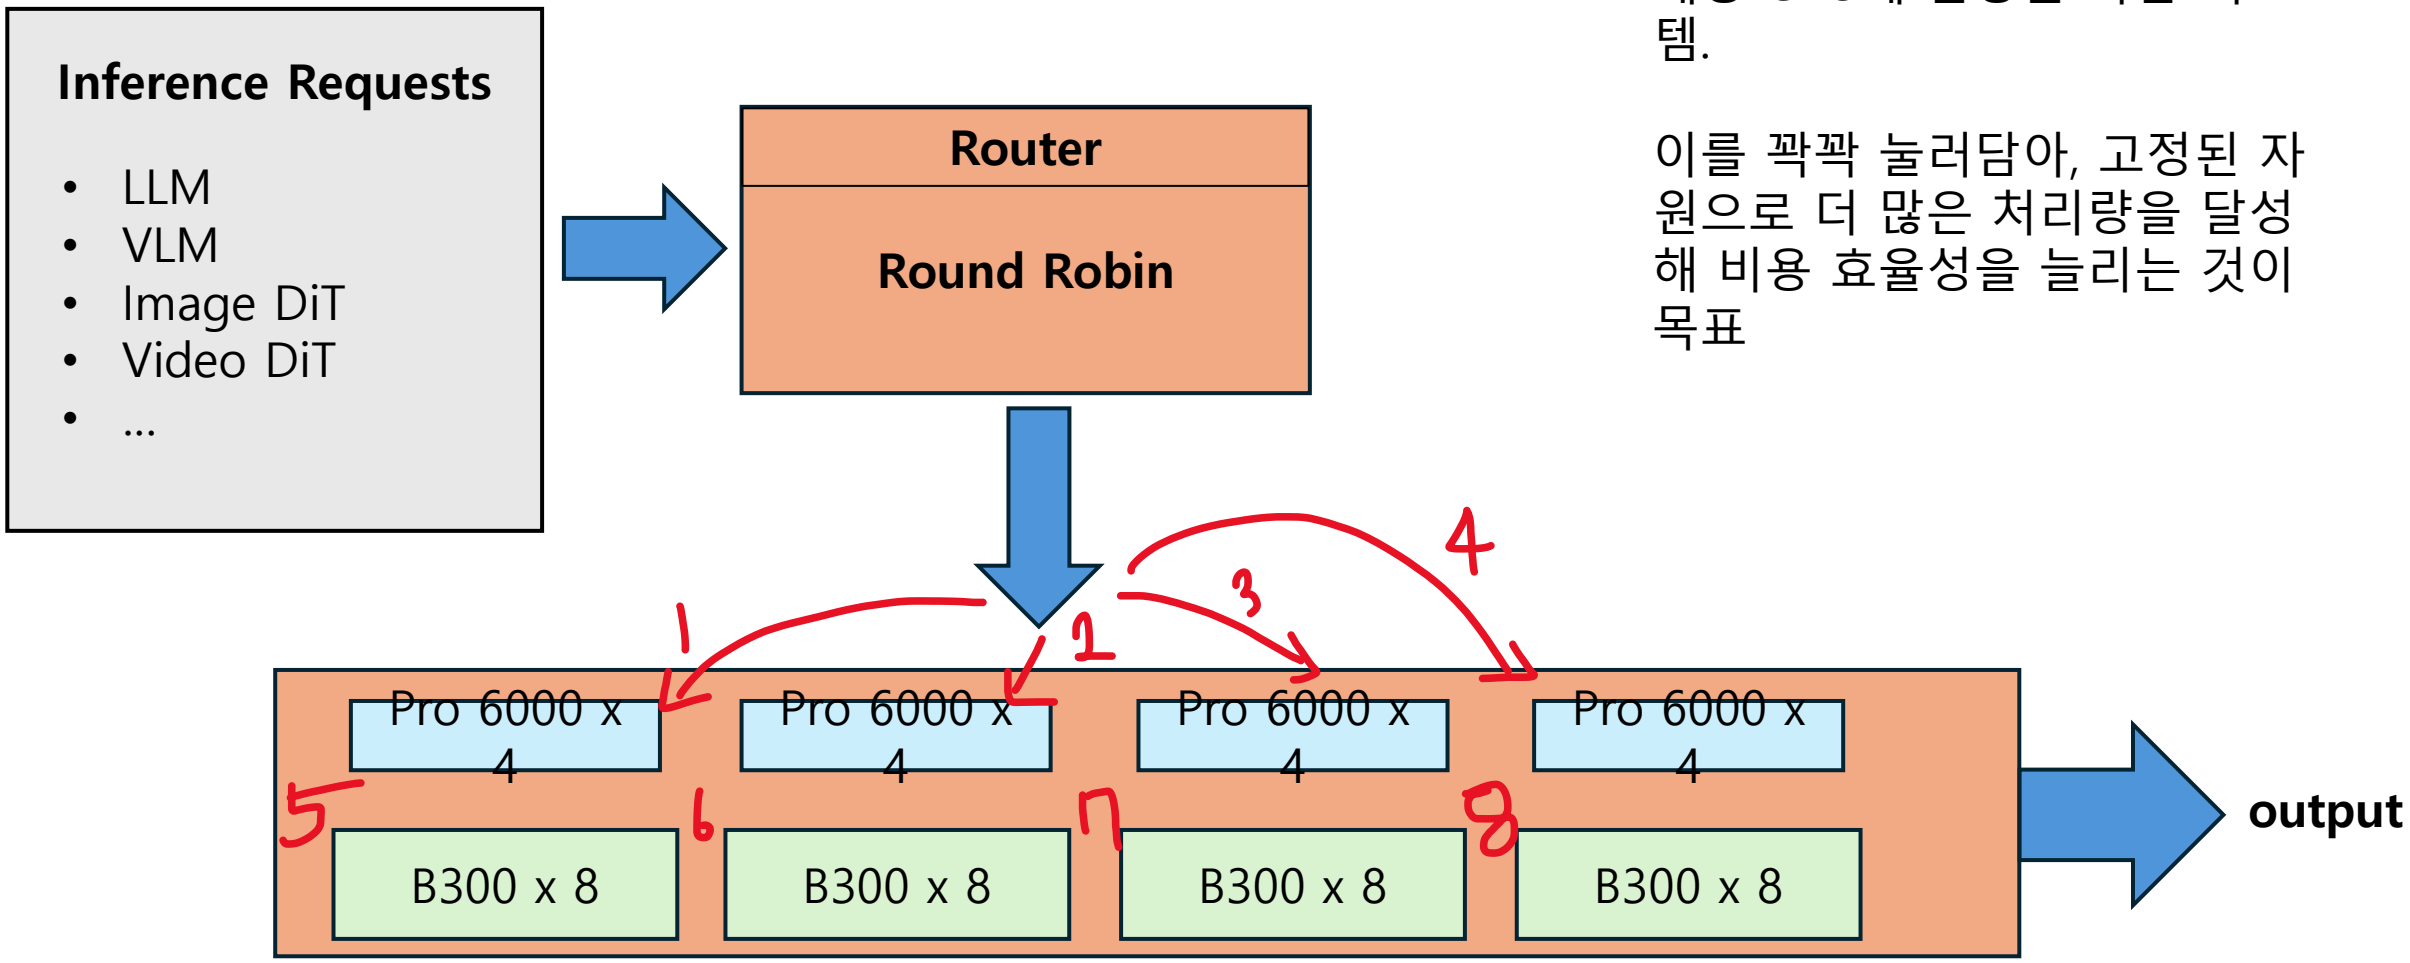
LLM-Pilot 확장

- LLM-Pilot
  - What's new
    - Attention Offloading (AO), AO(N:1), AO(N:N) 수학적 예측 (Latency 기반)
    - Attention을 이기종 디바이스에 배치하며 생긴 통신 비용 예측
    - 온라인 환경에서 SLO 만족하는 상황 고려 (TTFT, TPOT)
      - 기존엔 오프라인에서 TPS

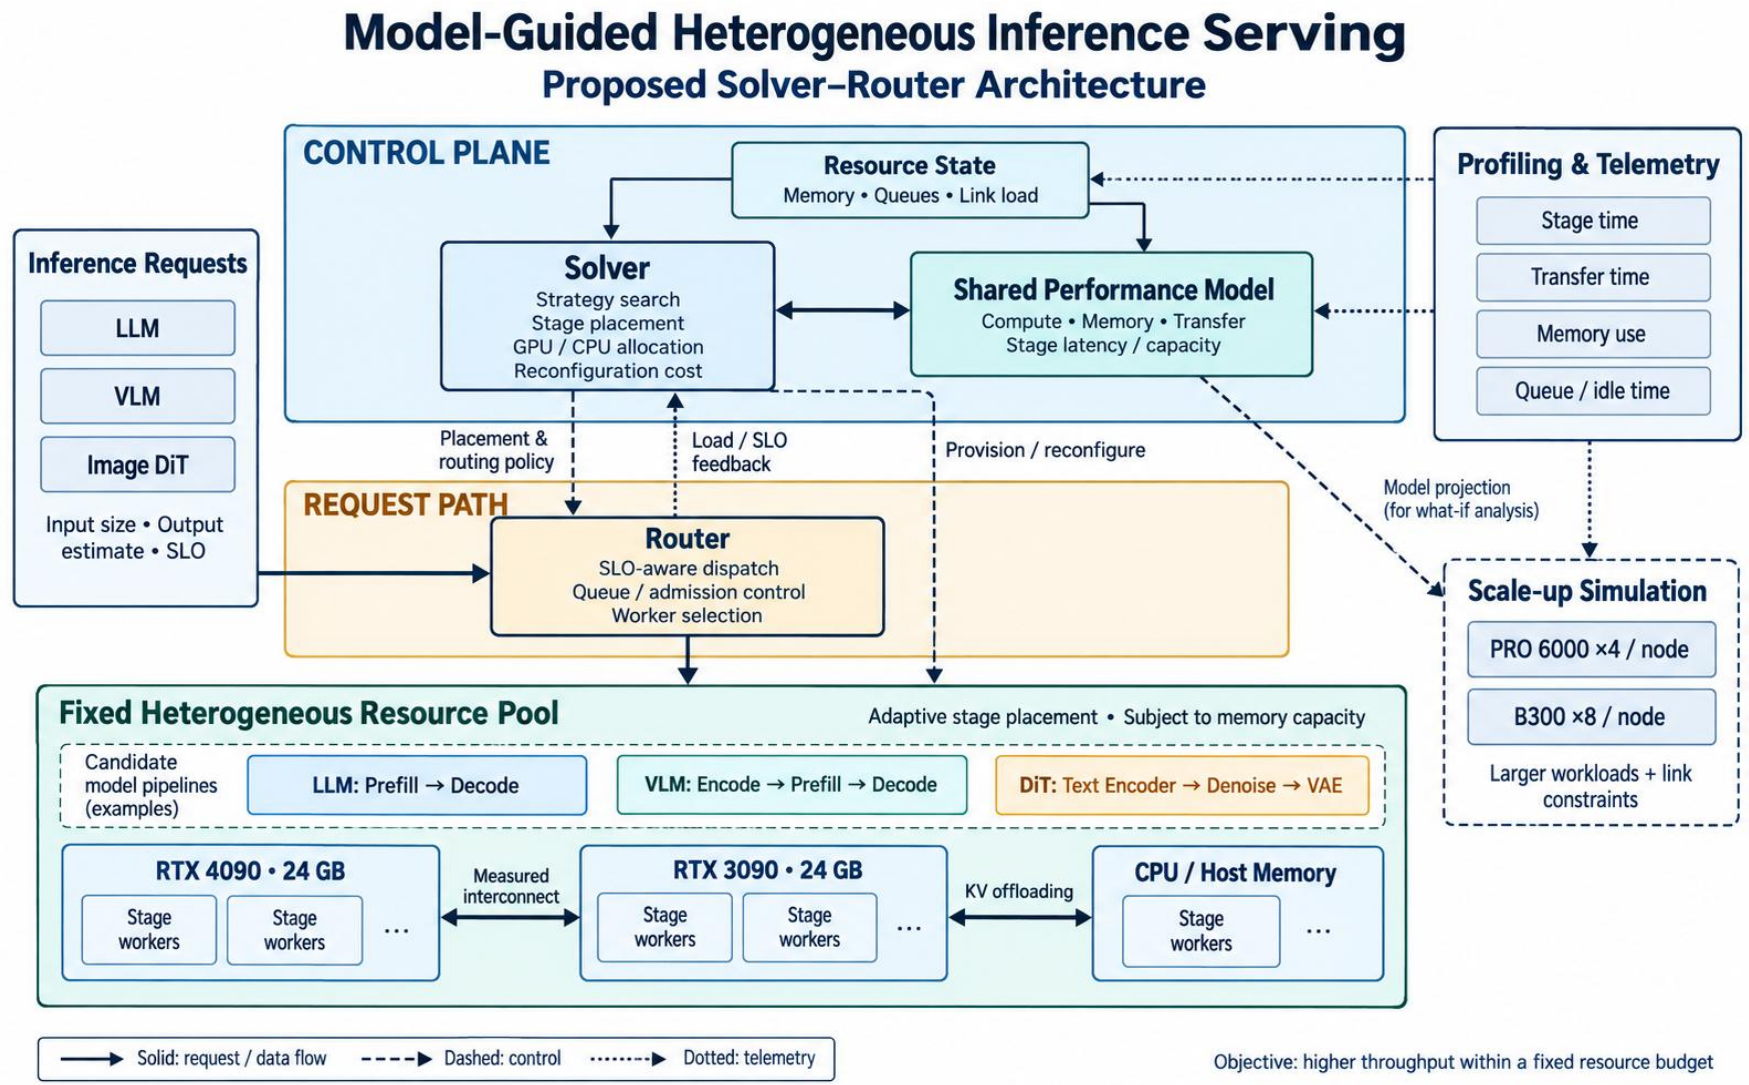
진행 중 프로젝트

요청의 종류에 상관없이, GPU 공간이 비어있으면 일단 요청을 해당 GPU에 할당을 하는 시스템.

이를 꽉꽉 눌러담아, 고정된 자원으로 더 많은 처리량을 달성해 비용 효율성을 늘리는 것이 목표



Final Overview



이기종 기법

- (LLM) PD 분할
- (DiT) VAE detached mechanism
- (VLM) EPD (Encoder / Prefill / Deocde) 분할

이기종 기법

- (LLM) PD 분할
  - Prefill, Decode phase의 각각 연산, 메모리 바운트 특성을 이용해 비용 효율적인 LLM 추론
  - Prefill Machine
  - Decode Machine
- (DiT) VAE detached mechanism
- (VLM) EPD (Encoder / Prefill / Deocde) 분할

이기종 기법

- **(LLM) PD 분할**
  - Prefill, Decode phase의 각각 연산, 메모리 바운트 특성을 이용해 비용 효율적인 LLM 추론

- **(DiT) VAE detached mechanism**
  - DiT에서는 VAE를 떼어내는 특징을 활용해 이기종 기법을 활용...

- **(VLM) EPD (Encoder / Prefill / Deocde) 분할**
  - VLM에서는 Prefill, Decode phase 앞에 Encoder가 있음.

mLLM 계획

- 각각 다른 추론 모델에서 실험된 이기종 기법들은 멀티모달 추론 서빙 시 처리량 상향이 보장되지는 않음
- LLM이 추론 중 인 GPU에서 빈공간이 있어, dit, vlm의 이기종 기법으로 빈공간을 활용해 추론을 하는데, 언제 어떻게 할 지, 그리고 그 상황이 과연 비용 효율적인지 알기 어려움.

- AI 추론 서빙이 LLM에서 나아가 멀티모달(이미지,동영상)까지 포함.
- 업무 효율성 최대화 하기위해 기업에서는 자체 AI 플랫폼을 고도화해 멀티모달 서빙을 하려고함.
- 각 모델들은 서로 다른 특성을 지니고 있고, 보유한 컴퓨팅 자원에서 데이터 배치를 어떻게해야할지가 중요함

•(1) LLM 추론은 Prefill/Decode Phase로 이루어져 있으며, 연산, 메모리-바운드 특징을 이용 해 각 phase를 분할하여 디바이스에 배치시켜 이기종 환경 에서 처리량 향상 연구가 이루어졌다. (2) DiT 이미지 추론 은 Text Encoder / Denoise / VAE 단계로 이루어져있으며, Denoise가 E2E 지연의 90%, 메모리 footnote의 30%를 차지할때, VAE는 메모리의 50%를 차지하는 것으로 관찰된다. (3) VLM 추론은 EPD (Encode / Prefill / Decode) 분할연구를 통하여 LLM과 마찬가지로 각 Phase를 적합한 이기종 디바이스에 배치해 처리량이 향상된다. 이러한 연구들은 실제 AI 플랫폼에서 사용자들의 요청이 실시간으로 입력되는 환경에서, (가지고있는 자원에 비해) 효율적인 처리량을 달성 가능하게 한다. 하지만, 각 추론 Task들의 입력들을 언제,어떤 전략으로 이기종 환경에서 특정 전략을 사용할지 판단하기에 고려할 사항들은 제약으로 작용한다.

•AI의 고도화에 따라 많은 Operator들은 자원 확보의 중요성을 인식하고, 기존 보유하고 있는 자원에 더해 향후 급변하는 AI 생태계에 즉각적으로 대응하기위해 더 나은 컴퓨팅자원을 확보하고있다. 하지만, Operator 뿐만아니라 제조업체들 또한 AI 생태계에서 새로운 디바이스를 빠르게 출시하고있어, 컴퓨팅 자원 sync에 어려움을 겪고있다. 기존 컴퓨팅 자원들은 (예, GPU, NVMe-backed Storage) 새로운 자원들과 상이한 Architecture를 가지고 있을 뿐만아니라, 지원가능한 소프트웨어마저 기존 장비로 사용불가능한 경우가발생한다 (ex, RTX 30xx, 40xx could not use CUDA 13.0).따라서, 최신 연구들이 이기종 환경에서의 AI 추론에 대하여새로운 제안을 함에도 불구하고, 실제 기술을 활용해야 하는

•operator-level에서는 고정된 On-premise 클러스터에서 요구사항과 제약사항을 고려해 최적의 AI 서빙을 할 수 있을지비효율적인 고민이 필연적으로 발생한다.

•멀티모달 AI 모델의 다양한 자원 활용 특성과 현실적인 컴퓨팅 자원의 제약은 플랫폼 Operator와 플랫폼 사용자 모두에게 짐이 지어진다. 플랫폼 Operator는 고정된 On-premise GPU 클러스터에서 최소한의 비용으로, 가지고있는 자원에서 최대한 많은 사용자에게 서비스를 제공하여 최대 비용 효율성을 달성해야 하는 목적을 가진다. 또한, 최대 비용 효율성 달성 목적과 동시에 사용자 요구사항 (Service-level Objective,SLO)를 최대한 달성해 사용자를 만족 시켜야하는 의무도 있다. 플랫폼 사용자들은 고정된 자원에서 서비스되는 AI 플랫폼에서 비효율적인 서빙시 발생하는 문제를 감당해야하는 상황이 발생한다. 실시간 서빙 특성상 사용자들의 요청이 몰리는 시간에 Heavy Workload에 대한 서비스가 필요하면, 높은SLO 달성을 기대하기 힘들다. 게다가, 동일한 조건의 사용자의 만족도가 달라짐에 따라 부정적으로 변하는 fairness 지표는 사용자들의 불만으로 이어진다. 고정된 컴퓨팅 자원에서 SLO를 만족하며 최소한의 비용으로 사용자들의 fairness를보장하며 최대 비용효율성을 달성 할 수 있게 각 사용자들의요청에 따