LLM-Pilot Recap

클라우드에서 LLM 추론 서빙을 할 때 , **SLO 를 만족하면서 가장 비용 효율적인 인스턴스 · 오프로딩 구성**을 자동으로 골라 주는 Solver (CCGrid 2026)

풀려던 문제

- 클라우드 인스턴스는 GPU·CPU· 메모리 · 네트워크가 묶음으로 팔리고 시간 단위로 과금
- 오프로딩 전략 (없음 / KVO / AO) 과 인스턴스 종류의 조합이 너무 많음
- 비싼 GPU 가 늘 답은 아님 — 워크로드와 SLO 에 따라 최적 조합이 달라짐
- 하나씩 실측해 보기에는 비용 · 시간이 큼

① 입력

워크로드 (입력 · 출력 길이 , 배치), 모델 ,
SLO(TTFT·TBT·TPS), 예산

② 해석적 성능 모델

연산량 F · 메모리 M · 전송량 D 로 단계별 지연 예측 ,
소량 실측으로 선형 보정

③ Solver

SLO· 예산을 어기는 조합을 걸러내고
남은 것 중 비용 효율 (CE = 토큰 /$) 최대를 선택

결과 (AWS 실측)

2.31×

기존 최선 대비 비용 효율 (토큰 /$)

실행 가능

실시간 SLO 에서 기존 방법이 전부 불가능 판정인 예산 구간에서도 구성을 찾아냄

핵심 아이디어 : 빠른 자원이 아니라 ' 워크로드와 SLO 에 맞는 ' 자원을 모델로 고른다 → 이번 연구는 이 틀을 고정 온프레미스 이기종 GPU 풀과 멀티모달로 확장