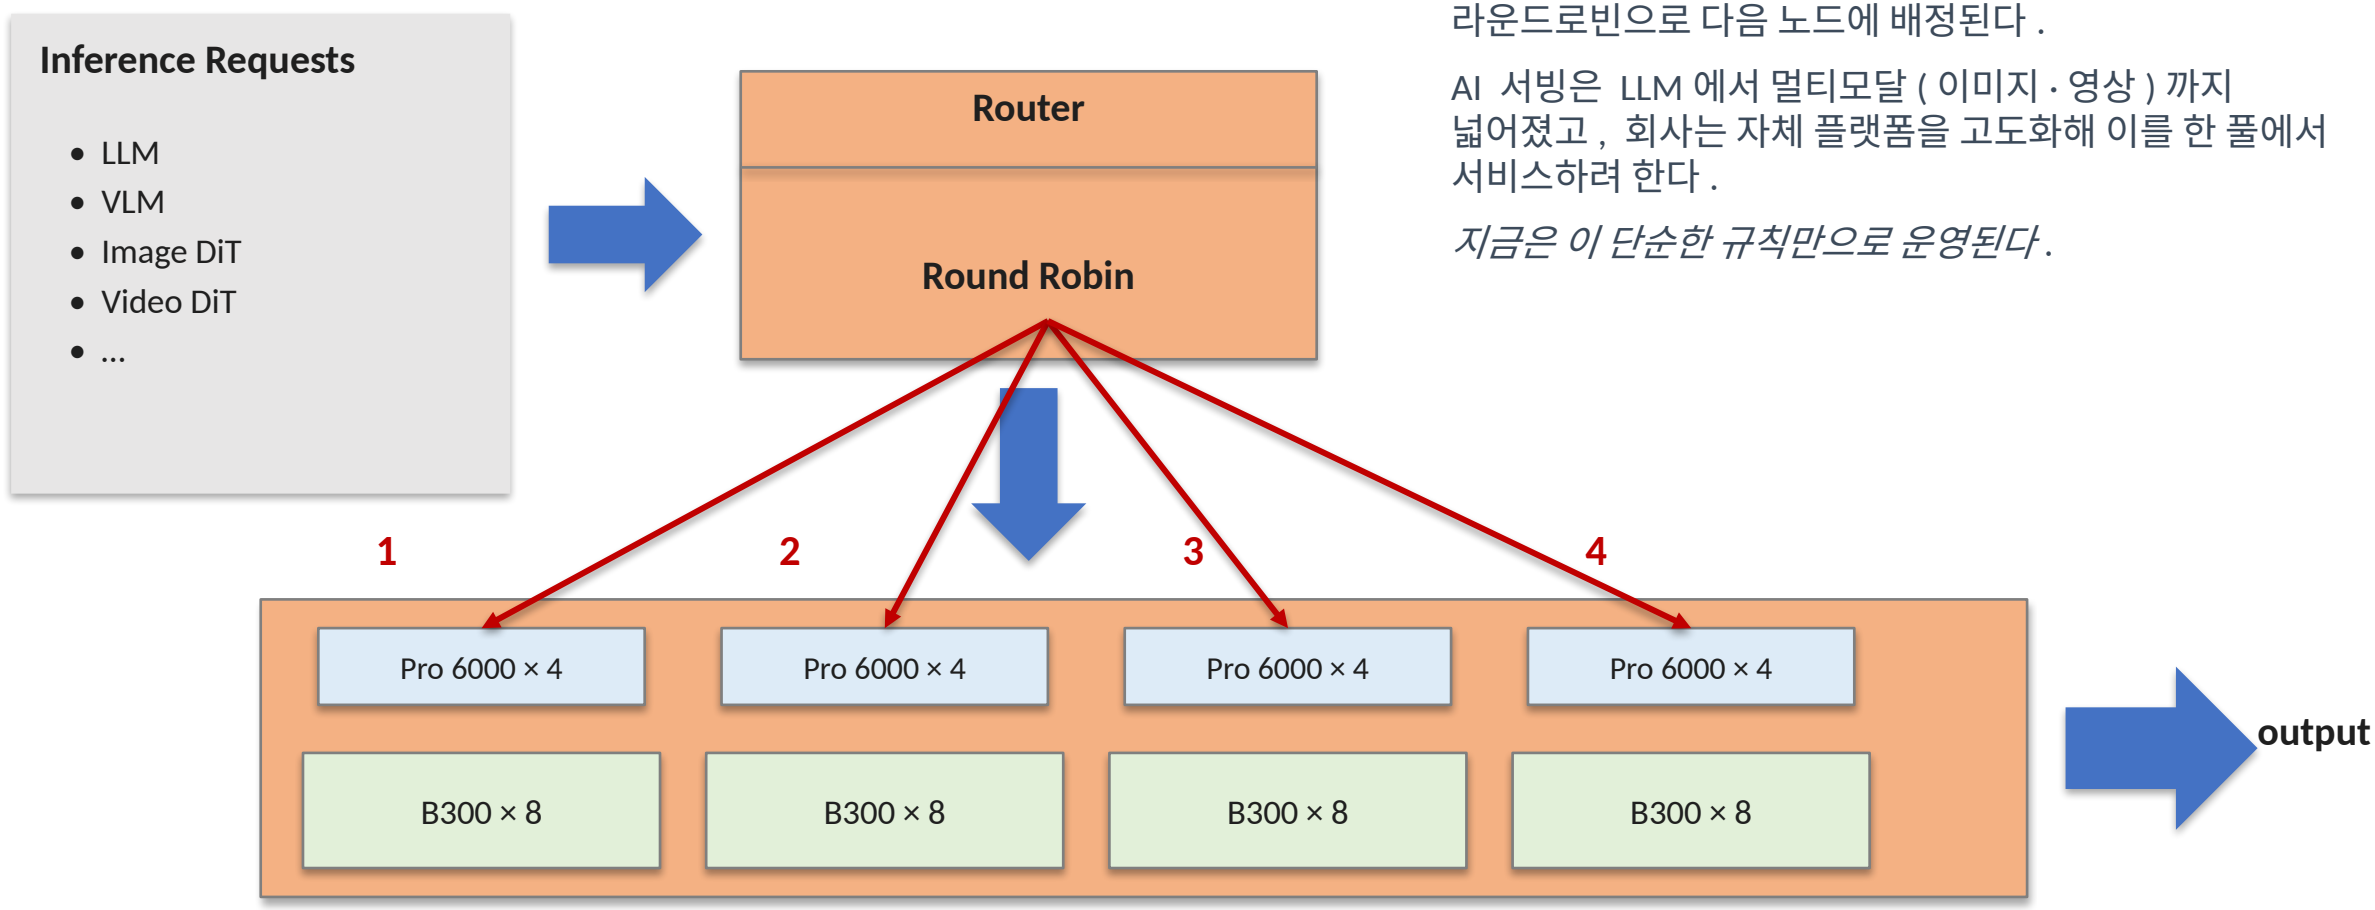
진행 중 프로젝트 ① 지금의 플랫폼

요청 종류에 상관없이 , **GPU 가 비어 있으면 그 GPU 에 넣는다 .**

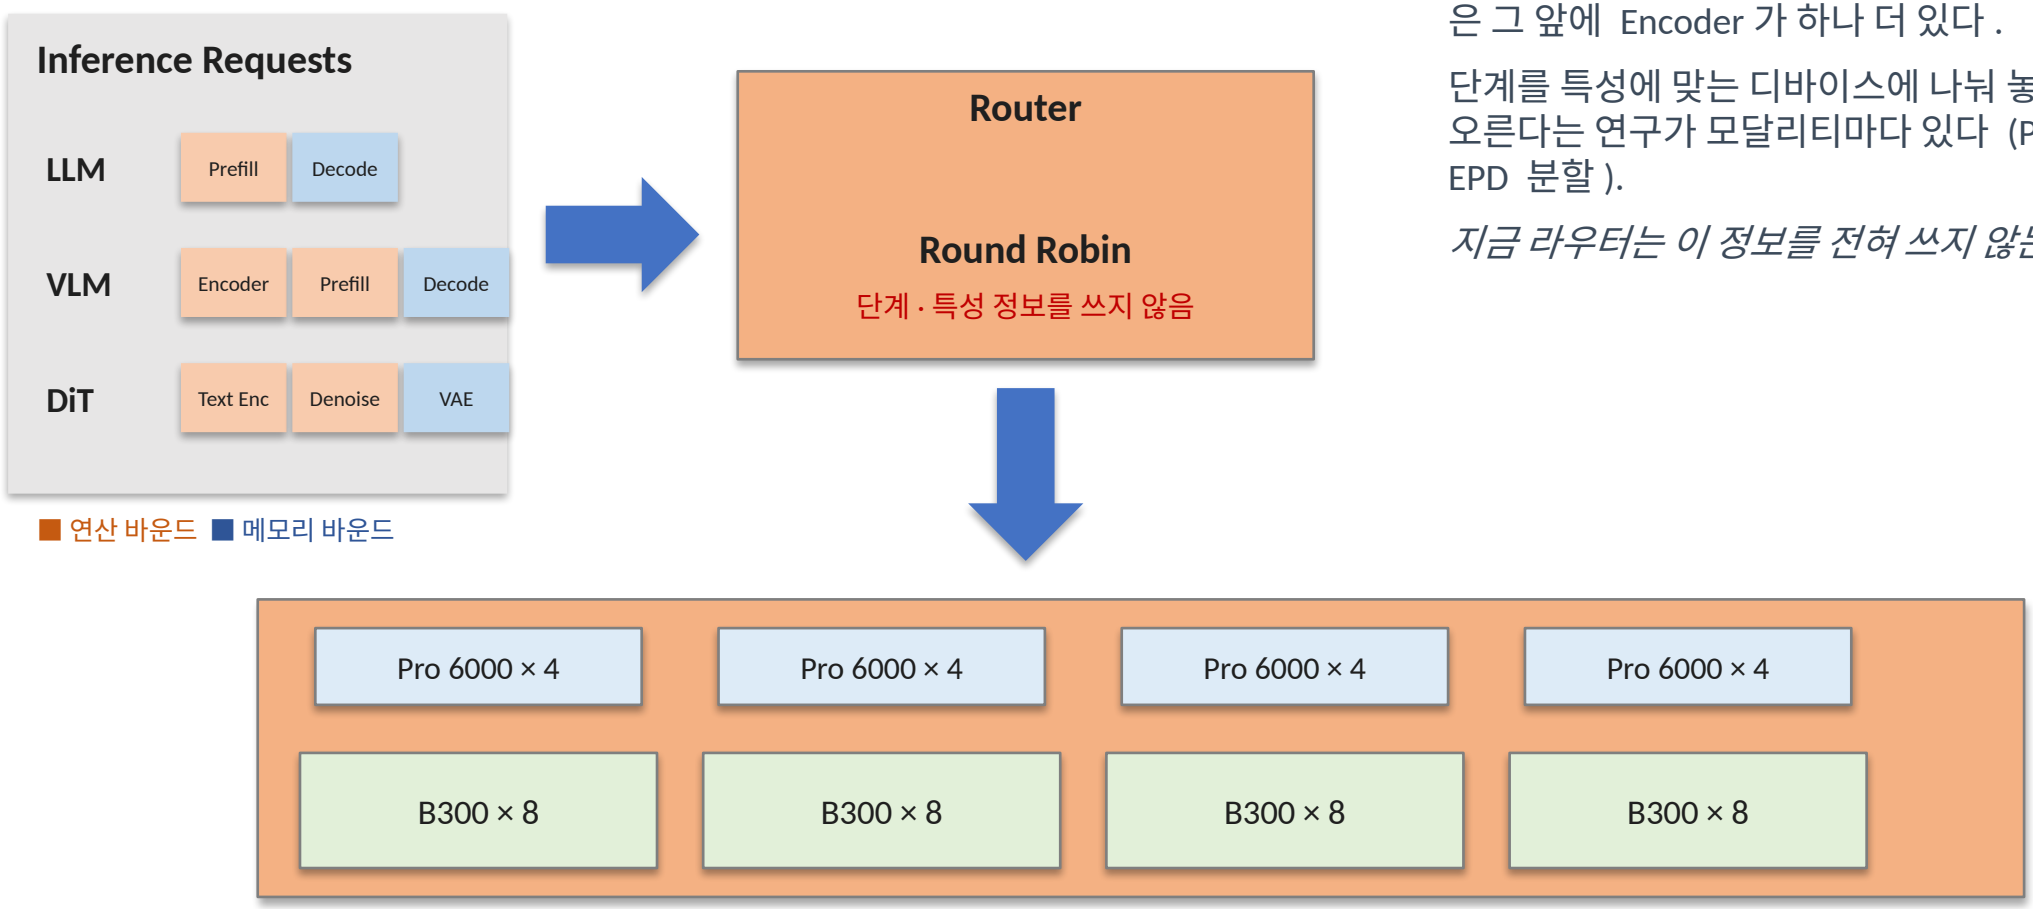
LLM·VLM· 이미지 · 영상 생성 요청이 한 라우터로 들어오고 , 라운드로빈으로 다음 노드에 배정된다 .

AI 서빙은 LLM 에서 멀티모달 (이미지 · 영상) 까지 넓어졌고 , 회사는 자체 플랫폼을 고도화해 이를 한 풀에서 서비스하려 한다 .

지금은 이 단순한 규칙만으로 운영된다 .



진행 중 프로젝트 ② 요청마다 무거운 단계가 다르다



■ 연산 바운드 ■ 메모리 바운드

같은 요청이라도 어느 카드, 어느 단계에 놓이느냐에 따라 처리량 · 지연이 달라진다

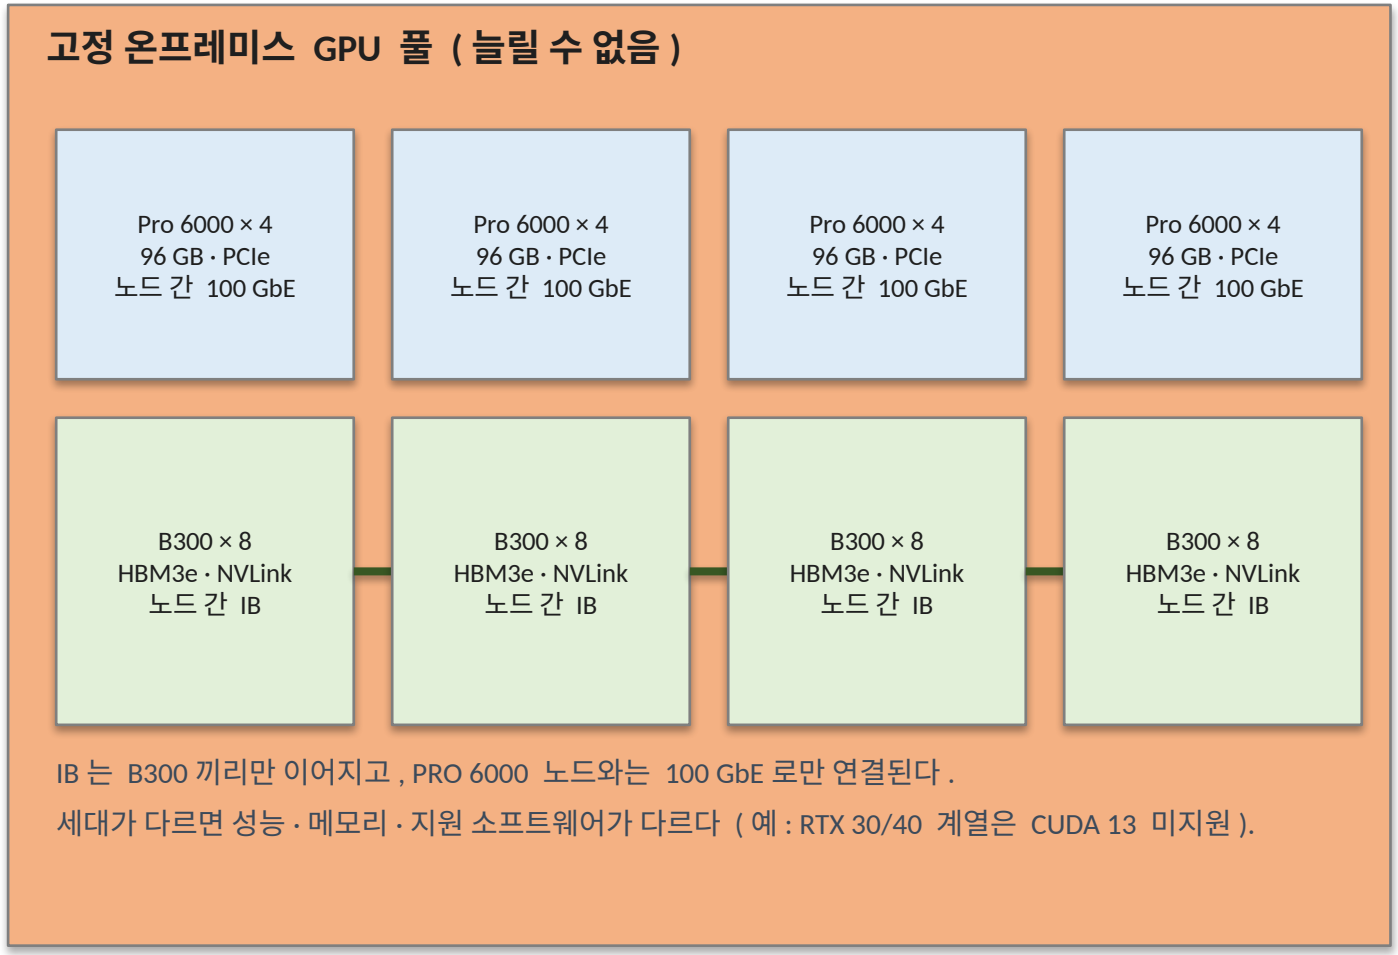
각 모델은 자원 특성이 다르다 .

LLM 은 Prefill(연산) 과 Decode(메모리), DiT 는 Denoise(연산 , E2E 의 90%) 와 VAE(메모리의 50%), VLM 은 그 앞에 Encoder 가 하나 더 있다 .

단계를 특성에 맞는 디바이스에 나눠 놓으면 처리량이 오른다는 연구가 모달리티마다 있다 (PD 분할 , VAE 분리 , EPD 분할).

지금 라우터는 이 정보를 전혀 쓰지 않는다 .

진행 중 프로젝트 ③ 자원은 고정이고 , 세대가 섞여 있다



자원은 고정이다 .

운영자는 급변하는 AI 생태계에 대응하려 더 나은 자원을 확보하지만 , 제조사도 새 장비를 빠르게 내놓아 세대가 섞인 풀이 된다 .

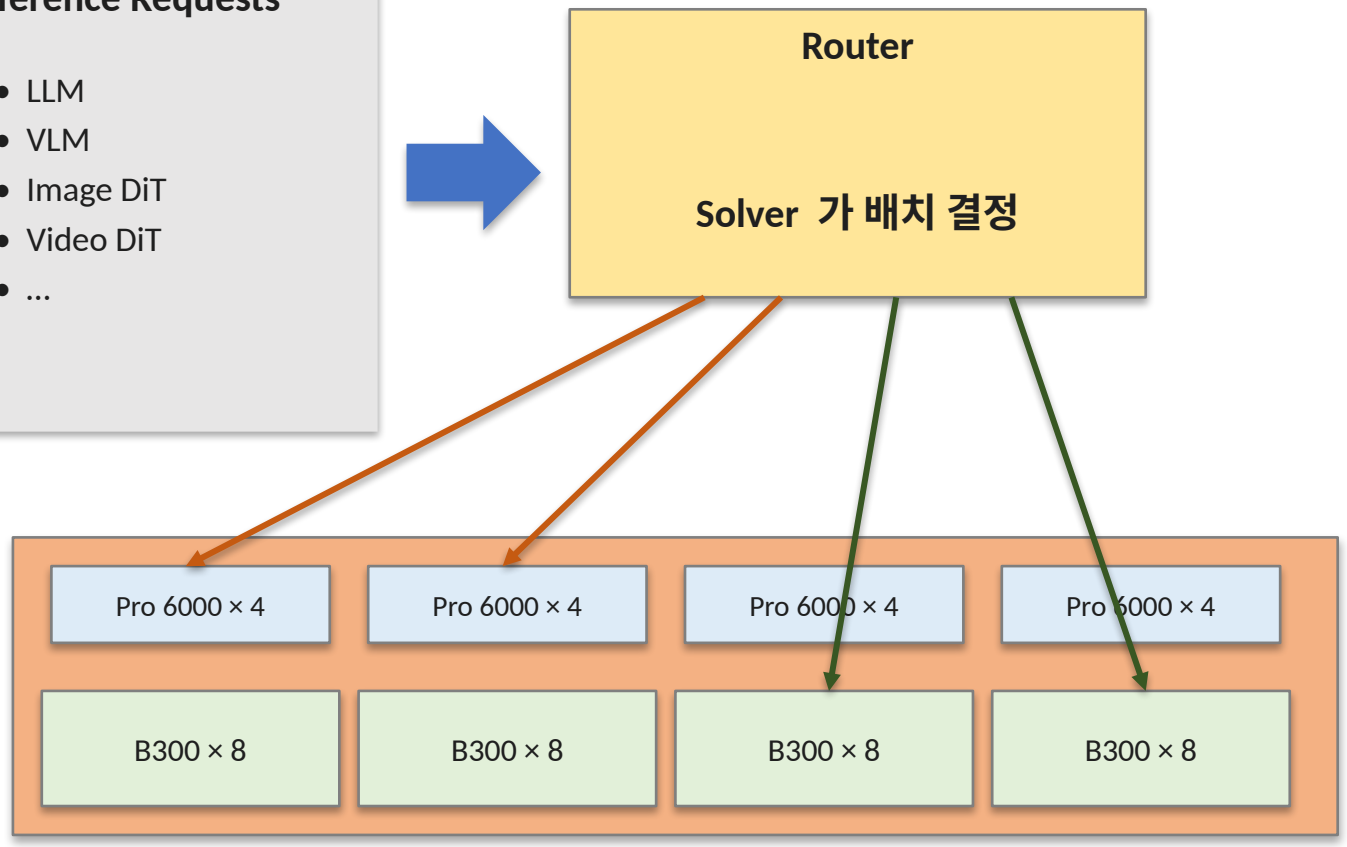
기존 장비는 아키텍처와 지원 소프트웨어가 달라 , 최신 연구의 기법을 그대로 적용할 수 없는 경우가 생긴다 .

그래서 운영자는 ' 이 제약 안에서 어떻게 배치해야 최적인가 ' 를 매번 고민하게 된다 .

진행 중 프로젝트 ④ 목표 : 같은 풀에서 SLO 를 지키며 비용 효율 최대

Inference Requests

- LLM
- VLM
- Image DiT
- Video DiT
- …



요청의 종류 · 단계 · SLO 를 보고, 맞는 카드와 분할 방식을 고른다

운영자

고정 자원에서 최소 비용으로 최대한 많은 사용자를 서비스
→ 비용 효율 최대

동시에 사용자 SLO 를 지킬 의무

사용자

몰리는 시간에 무거운 요청이 오면 SLO 가 깨짐

같은 조건인데 대우가 달라지면 공정성 불만

Solver

요청마다 SLO 를 만족하는 가장 비용 효율적인 자원 · 분할 방식을 정한다